

Efficient and Robust Automated Machine Learning

Bucevschi Alexandru¹ and Stoleru Ingrid¹

¹Facultatea de Informatica
Universitatea "Alexandru Ioan Cuza"

January 16, 2020

Outline

1 Prezentarea subiectului

- Automated Machine Learning
- Formularea problemei

2 AutoML modelata ca o problema CASH

- Optimizarea Bayesiană
- Modelul propus

3 Elementul de noutate

- Meta-learning pentru selectarea instantierilor de framework
- Constructia automata de ansambluri din modelele evaluate la faza de optimizare

4 Componenta practica a sistemului

**Automatizarea procesului de aplicare a abordarilor de ML
in problemele de zi cu zi.**

AutoML - problemele adresate

- Detectia automata a tipurilor datelor de intrare
- Determinarea automata a task-ului: clusterizare, clasificare binara/ multi-class
- Automatizarea procesului de feature engineering (selection/extraction)
- Selectarea automata a modelului
- Optimizarea automata a hiperparametrilor

Subiectul paper-ului

Paper-ul curent propune un nou sistem de **AutoML**, intitulat AUTO-SKLEARN.

Acesta este bazat pe **scikit-learn**:

- machine learning library (Python)
- 15 clasificatori
- 14 metode de feature preprocessing
- 4 metode de data preprocessing

Avantajele sistemului propus

la in calcul in mod automat performantele anterioare pe dataset-uri similare si construieste ensemble-uri din modelele evaluate la faza de optimizare.

Problema AutoML:

Producerea automata (fara interventia utilizatorului) a predictiilor pentru un set nou de date, intr-un buget computational fix.

Buget computational = Memorie, CPU

Definition 1 (AutoML problem). For $i = 1, \dots, n+m$, let $\mathbf{x}_i \in \mathbb{R}^d$ denote a feature vector and $y_i \in Y$ the corresponding target value. Given a training dataset $D_{train} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$ and the feature vectors $\mathbf{x}_{n+1}, \dots, \mathbf{x}_{n+m}$ of a test dataset $D_{test} = \{(\mathbf{x}_{n+1}, y_{n+1}), \dots, (\mathbf{x}_{n+m}, y_{n+m})\}$ drawn from the same underlying data distribution, as well as a resource budget b and a loss metric $\mathcal{L}(\cdot, \cdot)$, the AutoML problem is to (automatically) produce test set predictions $\hat{y}_{n+1}, \dots, \hat{y}_{n+m}$. The loss of a solution $\hat{y}_{n+1}, \dots, \hat{y}_{n+m}$ to the AutoML problem is given by $\frac{1}{m} \sum_{j=1}^m \mathcal{L}(\hat{y}_{n+j}, y_{n+j})$.

Probleme AutoML

- Niciun algoritm individual de ML nu performeaza foarte bine pe toate seturile de date.
- Unele abordari de ML se bazeaza pe optimizarea de hiperparametri (SVM-ul non-linear).

Combined Algorithm Selection and Hyperparameter optimization

Definition 2 (CASH). Let $\mathcal{A} = \{A^{(1)}, \dots, A^{(R)}\}$ be a set of algorithms, and let the hyperparameters of each algorithm $A^{(j)}$ have domain $\Lambda^{(j)}$. Further, let $D_{train} = \{(x_1, y_1), \dots, (x_n, y_n)\}$ be a training set which is split into K cross-validation folds $\{D_{valid}^{(1)}, \dots, D_{valid}^{(K)}\}$ and $\{D_{train}^{(1)}, \dots, D_{train}^{(K)}\}$ such that $D_{train}^{(i)} = D_{train} \setminus D_{valid}^{(i)}$ for $i = 1, \dots, K$. Finally, let $\mathcal{L}(A_{\lambda}^{(j)}, D_{train}^{(i)}, D_{valid}^{(i)})$ denote the loss that algorithm $A^{(j)}$ achieves on $D_{valid}^{(i)}$ when trained on $D_{train}^{(i)}$ with hyperparameters λ . Then, the Combined Algorithm Selection and Hyperparameter optimization (CASH) problem is to find the joint algorithm and hyperparameter setting that minimizes this loss:

$$A^*, \lambda_* \in \underset{A^{(j)} \in \mathcal{A}, \lambda \in \Lambda^{(j)}}{\operatorname{argmin}} \quad \frac{1}{K} \sum_{i=1}^K \mathcal{L}(A_{\lambda}^{(j)}, D_{train}^{(i)}, D_{valid}^{(i)}). \quad (1)$$

CASH - Aim

Incercam sa identificam o combinatie de algoritmi din tot spatiul de algoritmi, cu hiperparametrii corespunzatori, care performeaza cel mai bine pe toate seturile de date.
(Minimizeaza functia de loss, deci numarul de instante clasificate gresit)

$$x^{\star} = \arg \min_{x \in \mathcal{X}} f(x)$$

- Nu avem gradientii functiei
- Evaluarea functiei este costisitoare
- Optimizarea - Strategie secventiala (colectam date, apoi pe baza lor decidem ce punct vom evalua in continuare)

Optimizarea Bayesiană

- Metoda iterativa
- Ține cont de evaluările din trecut, formand un model probabilistic
- Mapeaza hiperparametrii la probabilitatea de a obtine un anumit scor

Optimizarea Bayesiană

$$P(\textit{score} \mid \textit{hyperparameters})$$

Optimizarea Bayesiană

- "Surogatul funcției obiectiv"
- Mai ușor de optimizat decât funcția obiectiv
- Selectează hiperparametrii care performează cel mai bine pe funcția surrogat
- Calculează valoarea funcției obiectiv și face update la surrogat

"Spend a little more time selecting the next hyperparameters in order to make fewer calls to the objective function."

Avantajele modelului propus




Figure 1: Our improved AutoML approach. We add two components to Bayesian hyperparameter optimization of an ML framework: meta-learning for initializing the Bayesian optimizer and automated ensemble construction from configurations evaluated during optimization.

Complementaritatea

- Meta-learning-ul sugereaza instantieri ale framework-ului care sunt probabile sa performeze bine
- Optimizarea bayesiana realizeaza fine-tuningul pe partea de performanta

Imaginea de ansamblu

- Se selecteaza k configurari pe baza meta-learningului
- Se initializeaza un algoritm de optimizare bayesiana cu aceste configurari

Generarea configuratiilor initiale

- S-a pornit de la repo-ul de OpenML - **140 dataseturi**
- S-au implementat 38 de meta-feature-uri, ce caracterizeaza dataseturile
- Exemple de feature-uri:
 - Statistici despre numarul de instante, feature-uri si clase
 - Entropia label-urilor
 - Data skewness

Meta Learning

- Pentru fiecare dataset, s-au evaluat feature-urile
- A fost folosita optimizarea bayesiana pentru a determina o instantiere a frameworkului cu rezultate foarte bune pe acel dataset.

Evaluarea pe un dataset nou

- Se calculeaza meta-feature-urile
- Se calculeaza distanta L1 fata de celelalte dataset-uri in spatiul de feature-uri
- Se aleg cele mai apropiate 25 de dataset-uri si se stocheaza instantierile corespunzatoare, care sunt date optimizatorului

Problema optimizarii bayesiene

O procedura ce consuma resurse utile, in sensul in care modelele care performeaza aproape la fel de bine ca cel mai bun sunt pierdute.

Stocheaza cele mai performante modele si printr-o serie de preprocesari, construiești un ansamblu din acestea.

- Robustete
- Reducerea overfitting-ului

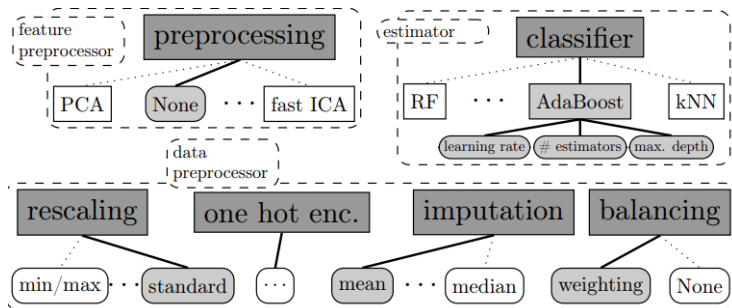
- Weight-urile uniforme asociate modelelor individuale nu au condus la rezultate bune.
- Metoda optimizata de construire a ansamblurilor - **ensemble selection**.
- Pornim de la un empty ensemble si in mod iterativ adaugam modele care maximizeaza performanta ansamblului la validare.
- Modelele sunt adaugate cu weighturi uniforme, insa se permit repetitiile.
- Dimensiunea ansamblului: **50**

- Porneste de la **scikit-learn** - ML library
- AUTO-WEKA (optimizarea bayesiana)
- AUTO-SKLEARN

Exemple

- Bayes Naiv, Arbori de decizie, KNN, SVM, AdaBoost
- PCA, ICA, Polynomial
- One-hot encoding, balansare, rescalare

Spatiu de configurare



**THANK YOU FOR YOUR
ATTENTION**

